

信函

通过深度强化学习实现人类级控制

Volodymyr Mnih¹*, Koray Kavukcuoglu¹*, David Silver¹*, Andrei A. Rusu¹, Joel Veness¹, Marc G. Bellemare¹, Alex Graves¹, Martin Riedmiller¹, Andreas K. Fidjeland¹, Georg Ostrovski¹, 斯蒂格·彼得森(1), 查尔斯·比蒂(1), 阿米尔·萨迪克(1), 伊奥尼斯·安东诺格鲁(1), 海伦·金(1), 达山·库马兰(1), 达恩·维斯特拉(1), 肖恩·莱格(1) & 德米斯·哈萨比斯(1)

强化学习理论提供了一种规范性解释¹，其根基深植于心理学²与神经科学³对动物行为的认知，阐释了智能体如何优化对环境的控制。

环境。然而要在接近现实复杂度的场景中成功应用强化学习，智能体面临着

面临一项艰巨任务：它们必须从高维感官输入中推导出高效的环境表征，并利用这些表征将过往经验推广至新情境。值得注意的是，人类和其他动物似乎通过强化学习与分层感官处理系统^(4,5)的和谐结合解决了这个问题，前者由大量神经数据所证实，这些数据揭示了多巴胺能神经元发出的相位信号与时间差强化学习算法⁽³⁾之间的显著相似性。尽管强化学习代理已在多个领域取得成功⁽⁶⁻⁸⁾，但其适用性此前仅限于可人工设计有用特征的领域，或具有完全可观测、低维状态空间的领域。本文利用深度神经网络训练领域的最新进展⁽⁹⁻¹¹⁾，开发出一种名为深度Q网络的新型人工智能体，该智能体能够通过端到端强化学习，直接从高维感官输入中学习成功策略。我们在经典雅达利2600游戏的严苛领域⁽¹²⁾对该智能体进行测试。实验表明，仅接收像素图像与游戏分数作为输入的深度Q网络智能体，在49款游戏中均超越了所有既有算法的性能，其表现达到专业人类游戏测试员的水平——且采用相同的算法、网络架构与超参数。这项工作弥合了高维感官输入与动作之间的鸿沟，造就了首个能够学习并精通多种高难度任务的人工智能代理。

我们致力于创建一种单一算法，使其能够在各种具有挑战性的任务中发展广泛的能力——这是通用人工智能的核心目标¹³，此前诸多努力均未能实现^{8,14,15}。为此，我们开发了一种新型智能体——深度Q网络（DQN），它能将强化学习与深度神经网络⁽¹⁶⁾这一类人工神经网络相结合。值得注意的是，深度神经网络⁽⁹⁻¹¹⁾的最新进展中，通过多层节点逐步构建出更抽象的表征结构¹⁷，这些数据使得人工神经网络能够学习

诸如物体类别等概念直接从原始感官数据中提取。我们采用一种特别成功的架构——深度卷积神经网络

网络¹⁷采用分层排列的卷积滤波器，通过模仿感受野效应——其灵感源自Hubel和Wiesel关于早期视觉皮层前馈处理的开创性研究¹⁸——从而利用图像中的局部空间相关性，并构建出对自然变换（如视角或尺度变化）的鲁棒性。

我们研究的任务场景中，智能体通过观察、行动与奖励的序列与环境交互。该研究的目标在于

行为体的核心在于以最大化未来累积奖励的方式选择行动。更正式地说，我们运用深度卷积神经网络来近似最优动作价值函数

$$Q^*(s,a) \sim \max_p \mathbb{E} \left[\sum_{t=0}^{\infty} \gamma^t r_{t+1} \mid s_t = s, a_t = a, p \right]$$

即在每次时间步 t 处，通过行为策略 $p \in \mathcal{P}(a|s)$ 在观察状态 (s) 并采取动作 (a) 后，能够实现的奖励 r_t 经系数 γ 折现后的最大总和（详见方法部分¹⁹）。

当使用神经网络等非线性函数逼近器表示动作价值函数（亦称Q函数）时，强化学习已知会出现不稳定甚至发散现象²⁰。这种不稳定性由多方面因素造成：观测序列中的相关性、Q值的微小更新可能显著改变策略从而改变数据分布，以及动作价值(Q)与目标值 $r + \gamma \max_{a'} Q(s', a')$ 之间的关联性。

我们通过一种新型的Q学习变体来解决这些不稳定性，该方法包含两大核心思路：首先，我们采用生物启发的经验回放机制²¹⁻²³，通过对数据进行随机化处理，消除观测序列中的相关性并平滑数据分布变化（详见下文）。其次，我们采用迭代更新机制，将动作值（Q）逐步调整至仅周期性更新的目标值，从而降低与目标值的相关性。

虽然强化学习环境中存在其他稳定的神经网络训练方法（如神经拟合Q迭代法²⁴），但这些方法需要在数百次迭代中反复从头训练网络。因此，与我们的算法不同，这些方法效率过低，无法成功应用于大型神经网络。我们通过图1所示的深度卷积神经网络对近似价值函数 $Q(s,a;h_{(i)})$ 进行参数化，其中 $h_{(i)}$ 是迭代 i 时Q网络的参数（即权重）。为实现经验回放，我们将智能体在每个时间步 t 的经验 $e_{(t)} = (s_{(t)}, a_{(t)}, r_{(t)}, s_{(t+1)})$ 存储于数据集 $D_{(i)} = \{e_{(1)}, \dots, e_{(i)}\}$ 中。学习过程中，我们对从存储样本池中均匀随机抽取的经验样本（或小批次） (s,a,r,s') 进行Q学习更新，其中 $U(D)$ 表示经验样本池。迭代的Q学习更新采用以下损失函数：

$$L_i(h_i) \sim \mathbb{E}_{(s,a,r,s') \sim U(D)} \left[\left(r + \gamma \max_{a'} Q(s', a'; h_i) - Q(s, a; h_i) \right)^2 \right] \quad (2)$$

其中 γ 是决定智能体规划时限的贴现因子， h_i 是迭代 i 时Q网络的参数， h' 是用于计算迭代 i 目标值的网络参数。目标网络参数 h' 仅在每 c 步更新时与Q网络参数 (h_i) 同步更新，在两次更新之间保持固定（详见方法部分）。

为评估DQN智能体，我们采用Atari 2600平台，该平台提供多样化任务（ $n=49$ ），旨在

¹ 谷歌DeepMind，英国伦敦EC4A 3TW新街广场5号。

*本文作者贡献均等。




图1 | 卷积神经网络示意图。架构细节详见方法部分。神经网络输入由预处理映射 w 生成的 $84 \times 3 \times 84 \times 3 \times 4$ 图像构成，随后经过三层卷积层（注：蛇形蓝线）

对人类玩家而言既具挑战性又引人入胜。我们始终采用相同的网络架构、超参数值（详见扩展数据表1）及学习流程——以高维数据（ 210×160 像素、60Hz彩色视频）作为输入——以此证明：我们的方法仅凭极少先验知识（即输入数据仅为视觉图像、以及每款游戏中可用的动作数量，但不包含动作对应关系；详见方法部分）。值得注意的是，我们的方法能够通过强化学习信号和随机梯度下降稳定地训练大型神经网络——这通过两个学习指标的时序演变得到验证（代理的平均每局得分和平均预测Q值；详见图2及补充讨论部分）。

（图示为每个滤波器在输入图像上的滑动过程）及两个全连接层，每个有效动作对应单一输出。每个隐藏层后接整流非线性函数（即 $\max(0, x)$ ）。

我们在49款可获取结果的游戏，将DQN与强化学习文献中表现最佳的方法进行了对比^{12,15}。除学习型智能体外，我们还报告了专业人类游戏测试员在受控条件下的得分，以及采用均匀随机策略的得分（详见扩展数据表2和图3，纵轴标记为100%（人类）和0%（随机）；具体方法参见方法论部分）。我们的DQN方法在43款游戏中超越了现有最优强化学习方法，且未采用其他方法（如文献12、15）所使用的Atari 2600游戏额外先验知识。此外，在49款游戏的测试中，我们的DQN智能体表现可与专业人类游戏测试员媲美，在超过半数的游戏（29款）中达到人类得分的75%以上（




图2 | 追踪智能体平均得分与平均预测动作价值的训练曲线。a，每个点代表智能体在《太空侵略者》中采用 ϵ -贪婪策略（ $\epsilon=5, 0.05$ ）运行52万帧后每回合达到的平均得分。b，《海之征途》中每回合达到的平均得分。c，《太空侵略者》中保留状态集上的平均预测动作价值。曲线上的每个点

对应于在保留状态集上计算的动作价值Q的平均值。需注意Q值因奖励截断而经过缩放（详见方法部分）。d，Seaquest游戏中的平均预测动作价值。详见补充讨论部分。




图3 | DQN智能体与文献中最佳强化学习方法¹⁵的对比。DQN的性能以职业人类游戏测试员（即100%水平）和随机玩法（即0%水平）为基准进行归一化处理。需注意DQN的标准化表现（百分比形式）计算方式为： $100 \times \frac{\text{DQN得分} - \text{随机玩法得分}}{\text{人类得分} - \text{随机玩法得分}}$ 。由此可见DQN

在几乎所有游戏中，该方法都优于竞争方法（另见扩展数据表2），且在大多数游戏中表现出与专业人类游戏测试员相当或更优的水平（即操作化定义为75%或以上水平）。人类玩家和智能体均禁用了音频输出。误差条表示30个评估回合（初始条件各异）的标准差。

详见图3、补充讨论及扩展数据表2）。在额外模拟中（参见补充讨论及扩展数据表3和4），我们通过禁用DQN智能体各核心组件——回放记忆库、独立目标Q网络及深度卷积网络架构——并展示其性能下降的负面影响，验证了这些组件的重要性。

接下来，我们通过一种名为“t-SNE”²⁵的高维数据可视化技术（图4），分析了DQN在《太空侵略者》游戏中成功表现背后的学习表征（DQN表现演示见补充视频1）。正如预期，t-SNE算法倾向于将感知相似状态的DQN表征映射至邻近点。有趣的是，我们还发现某些情况下，该算法为预期奖励相近但

感知上差异显著（图4右下、左上及中间部分），这印证了网络能够从高维感官输入中学习支持适应性行为的表征。此外，我们还证明DQN学习到的表征能够泛化到其他策略生成的数据——在模拟实验中，我们将人类与智能体对弈时经历的游戏状态作为输入提供给网络，记录其最后隐藏层的表征，并通过t-SNE算法可视化生成的嵌入（扩展数据图1及补充讨论）。扩展数据图2进一步说明了DQN学习到的表征如何使其能够准确预测状态和动作价值。

值得注意的是，DQN在其中表现卓越的游戏类型极其多样，从横版射击游戏（《河流突袭》）到拳击游戏（《拳击》），再到三维赛车游戏（《耐力赛》）。




图4 | DQN在《太空侵略者》游戏过程中，对历经游戏状态在最后一层隐藏层的表示进行二维t-SNE嵌入。该图通过让DQN代理运行2小时真实游戏时间后，对每个游戏状态应用t-SNE算法²⁴处理。点位根据DQN预测的状态值（V，即状态的最大预期奖励）进行着色（从深红（最高V值）到深蓝（最低V值））。展示了对应选定数量点位的截图。DQN智能体

事实上，在某些游戏中，DQN能够发现相对长期的策略（例如《打砖块》：智能体学会了最优策略，即先在墙壁侧面挖掘隧道，使球能够绕到背面摧毁大量砖块；参见补充视频2，其中展示了DQN在训练过程中的性能发展）。然而，需要更长时间规划策略的游戏对所有现有智能体（包括DQN）仍构成重大挑战（例如《蒙特祖玛的复仇》）。

在本研究中，我们证明单一架构仅凭极少先验知识即可成功学习多种环境的控制策略：该架构仅接收像素数据与游戏分数作为输入，在每款游戏中采用相同的算法、网络架构和超参数，且仅掌握人类玩家所能获取的输入信息。与先前研究^(24,26)不同，我们的方法融合了“端到端”强化学习机制，通过奖励持续塑造卷积网络内的表征结构，使其聚焦于环境中利于价值评估的显著特征。该原理借鉴了神经生物学证据——感知学习过程中的奖励信号可能影响灵长类动物视觉皮层表征特征^(27,28)。值得注意的是，强化学习与深度网络架构的成功融合，关键取决于我们引入的回放算法⁽²¹⁻²³⁾——该算法涉及近期经历过渡状态的存储与表征。多项证据表明，海马体可能为这种物理机制提供支持。

对完整屏幕（右上截图）和近乎完整的屏幕（左下截图）都预测了较高的状态值，因为它已经学会了完成一个屏幕会导致出现一个充满敌方战舰的新屏幕。部分完成的屏幕（底部截图）被赋予较低的状态值，因为可获得的即时奖励较少。右下、左上及中间区域的屏幕在视觉上与其他示例差异较大，但仍被映射至相邻表示且获得相似数值——因橙色掩体在关卡末期已不具显著战略价值。经Square Enix Limited授权使用。

哺乳动物大脑中实现此类过程的机制，可能通过离线期（如清醒休息）对近期经历轨迹进行时间压缩的再激活来实现^{21,22}，该机制被认为能通过基底神经节的交互作用高效更新价值函数²²。未来研究需重点探索将经验回放内容偏向显著事件的潜在应用——这一现象既是海马体重放的实证特征⁽²⁹⁾，亦与强化学习中的“优先清扫”概念⁽³⁰⁾密切相关。综上所述，我们的研究展示了将尖端机器学习技术与生物启发机制相结合的强大能力，从而创造出能够学习掌握各种挑战性任务的智能体。

在线内容方法、任何额外的扩展数据展示项目及源数据均可在论文在线版本中查阅；这些章节特有的参考文献仅出现在在线论文中。

收稿日期：2014年7月10日；录用日期：2015年1月16日。

1. Sutton, R. & Barto, A. 《强化学习导论》（麻省理工学院出版社，1998年）。
2. 桑顿, R. & 巴托, A. 《强化学习：入门》（麻省理工出版社，1998）。
3. 舒尔茨, W., 戴安, P. & 芒塔古, P. R. 预测与奖励的神经基质。《科学》275, 1593–1599 (1997)。
4. Serre, T., Wolf, L. & Poggio, T. 基于视觉皮层特征的物体识别。Proc. IEEE Comput. Soc. Conf. Comput. Vis. Pattern. Recognit. 994–1000 (2005)。
5. 福岛, K. 新认知器：一种不受位置偏移影响的模式识别机制的自组织神经网络模型。生物控制论36, 193–202 (1980)。

6. Tesauro, G. 时差学习与TD-Gammon. *ACM通讯* 38, 58–68 (1995)。
7. 里德米勒, M., 加贝尔, T., 哈夫纳, R. & 朗格, S. 机器人足球的强化学习。《*自主机器人*》27卷, 55–73页 (2009)。
8. 迪乌克, C., 科恩, A. & 里特曼, M. L. 面向高效强化学习的面向对象表示法。《*国际机器学习会议论文集*》240–247 (2008)。
9. Bengio, Y. 人工智能深度架构的学习。《*机器学习基础与趋势*》2, 1–127 (2009)。
10. Krizhevsky, A., Sutskever, I. & Hinton, G. 基于深度卷积神经网络的ImageNet分类。《*神经信息处理系统进展*》25, 1106–1114 (2012)。
11. 辛顿, G. E. & 萨拉赫特迪诺夫, R. R. 用神经网络降低数据维度。《*科学*》313, 504–507 (2006)。
12. 贝尔马雷, M. G., 纳达夫, Y., 维内斯, J. & 鲍林, M. 《街机学习环境: 通用智能体的评估平台》。《*人工智能研究杂志*》47卷, 253–279页 (2013)。
13. Legg, S. & Hutter, M. 《通用智能: 机器智能的定义》。《*思维与机器*》17, 391–444 (2007)。
14. Genesereth, M., Love, N. & Pell, B. 通用游戏: AAAI 竞赛概述。《*人工智能杂志*》26, 62–72 (2005)。
15. Bellemare, M. G., Veness, J. & Bowling, M. 使用 Atari 2600 游戏研究偶然性意识。AAAI 会议论文集。《*人工智能*》864–871 (2012)。
16. McClelland, J. L., Rumelhart, D. E. & Group, T. P. R. 《并行分布式处理: 认知微结构探索》(麻省理工学院出版社, 1986年)。
17. LeCun, Y., Bottou, L., Bengio, Y. & Haffner, P. 基于梯度的学习在文档识别中的应用。《*IEEE学报*》86卷, 2278–2324页 (1998年)。
18. Hubel, D. H. & Wiesel, T. N. 猫纹状皮层中柱状结构的形态与排列。《*生理学杂志*》165, 559–568 (1963)。
19. Watkins, C. J. & Dayan, P. Q学习。《*机器学习*》8, 279–292 (1992)。
20. 齐齐克利斯, J. & 罗伊, B. V. 基于函数逼近的时间差分学习分析。《*IEEE自动控制汇刊*》42卷, 674–690页 (1997年)。
21. McClelland, J. L., McNaughton, B. L. & O'Reilly, R. C. 海马体与新皮层存在互补学习系统的缘由: 基于联结主义学习与记忆模型的成功与失败的洞见。《*心理学评论*》102, 419–457 (1995)。
22. 奥尼尔, J., 普莱德尔-布维里, B., 杜普雷, D. & 契克瓦里, J. 再次重现: 清醒体验与记忆的再激活。《*神经科学趋势*》33卷, 220–229页 (2010年)。
23. 林, L.-J. 基于神经网络的机器人强化学习。技术报告, DTIC文献 (1993)。
24. 里德米勒, M. 神经拟合Q迭代——一种数据高效神经强化学习方法的初步实践。《*机器学习: ECML*》, 3720, 317–328 (斯普林格出版社, 2005)。
25. 范德马滕, L. J. P. & 辛顿, G. E. 基于t-SNE的高维数据可视化。《*机器学习研究杂志*》9, 2579–2605 (2008)。
26. 兰格, S. & 里德米勒, M. 强化学习中的深度自编码神经网络。《*国际神经网络联合会议论文集*》1–8 (2010)。
27. Law, C.-T. & Gold, J. I. 强化学习可解释视觉决策任务中的联想与感知学习。《*自然神经科学*》12, 655 (2009)。
28. Sigala, N. & Logothetis, N. K. 视觉分类塑造灵长类动物颞叶皮层的特征选择性。《*自然*》415, 318–320 (2002)。
29. 本多尔, D. & 威尔逊, M. A. 睡眠期间海马再现内容的偏向作用。《*自然神经科学*》15卷, 1439–1444页 (2012年)。
30. Moore, A. & Atkeson, C. 优先级扫描: 用更少数据和更少实时进行强化学习。《*机器学习*》13, 103–130 (1993)。

补充信息详见论文在线版本。

致感谢信谢Hinton, P. Dayan和M. Bowling的讨论。

A. Cain 和 J. Keene 负责视觉效果制作, K. Keller 和 P. Rogers 协助视觉效果工作, G. Wayne 对早期稿件版本提出宝贵意见, 以及 DeepMind 团队其他成员提供的支持、创意和鼓励。

作者贡献 V.M., K.K., D.S., J.V., M.G.B., M.R., A.G., D.W., S.L. 和 D.H.

共同构思问题框架与技术架构。V.M., K.K., A.A.R. 与 D.S. 负责算法开发与测试。J.V., S.P., C.B., A.A.R., M.G.B., I.A., A.K.F., G.O. 及

A.S. 创建了测试平台。K.K., H.K., S.L. 和 D.H. 负责项目管理。K.K., D.K., D.H., V.M., D.S., A.G., A.A.R., J.V. 和 M.G.B. 共同撰写了本文。

作者信息重印及版权许可信息详见 www.nature.com/reprints。作者声明不存在任何财务利益冲突。欢迎读者对论文在线版本发表评论。通信及材料索取事宜请联系 K.K. (korayk@google.com) 或 D.H. (demishassabis@google.com)。

方法

预处理。直接处理原始Atari 2600帧数据（即210×160像素图像，采用128色调色板）会对计算能力和内存提出较高要求。我们实施基础预处理步骤，旨在降低输入维度并处理Atari 2600模拟器的部分伪像。首先，为编码单帧图像，我们取当前帧与前帧中每个像素颜色值的最大值。此步骤旨在消除游戏中的闪烁现象——当某些对象仅出现在偶数帧而另一些仅出现在奇数帧时，会因Atari 2600同时显示精灵数量的限制产生此类伪像。其次，从RGB帧中提取Y通道（即亮度通道），并将其缩放为84×84像素。下文所述算法1中的w函数将此预处理应用于最近m帧图像，将其堆叠后作为Q函数的输入。其中m通常取值5或4，但该算法对*值m*的不同取值（如3或5）具有鲁棒性。代码获取方式。源代码可通过 <https://sites.google.com/a/deepmind.com/dqn> 获取。

deepmind.com/dqn，仅限非商业用途。

模型架构。使用神经网络对Q进行参数化有多种可能方式。由于Q将历史·动作对映射为其Q值的标量估计，某些先前方法^[24,26]曾将历史和动作作为神经网络的输入。此类架构的主要缺陷在于：计算每个动作的Q值需要单独的前向传播，导致计算成本随动作数量呈线性增长。我们采用的架构则为：为每个可能动作设置独立输出单元，仅将状态表示作为神经网络输入。输出对应输入状态下各动作的预测Q值。此架构的核心优势在于：仅需单次网络前向传播即可计算给定状态下所有可能动作的Q值。具体架构如图1示意图所示：神经网络输入由预处理图w生成的84×3×84×3×4图像构成。第一隐藏层采用步长为4的32个8×3×8滤波器对输入图像进行卷积，并应用整流非线性函数^(31,32)。第二隐藏层采用步长为2的4×3×4尺寸滤波器（64个）进行卷积，同样接续整流非线性函数。随后第三卷积层采用步长为1的3×3×3尺寸滤波器（64个）进行卷积，后接整流函数。最终隐藏层为全连接层，包含512个整流单元。输出层为全连接线性层，每个有效动作对应单一输出。有效动作数量在4至

以及在我们考虑的游戏中获得18分。

训练细节。我们对49款Atari 2600游戏进行了实验，这些游戏中其他所有可比方法均有可用结果^[15]。每款游戏均采用独立训练网络：所有游戏均使用相同的网络架构、学习算法和超参数设置（详见扩展数据表1），这表明我们的方法在仅需极少先验知识的情况下（详见下文），仍能稳健地应用于各类游戏。虽然我们在未修改的游戏环境中评估代理，但在训练阶段对游戏奖励结构进行了单一调整。由于不同游戏的得分尺度差异显著，我们将所有正奖励截断为1，负奖励截断为21，0奖励保持不变。此类奖励截断可限制误差导数的尺度，便于在多款游戏中采用统一的学习率。同时，

2600仿真器还会发送游戏中剩余的生命数，该数值用于在训练期间标记剧集结束。

在这些实验中，我们采用了RMSProp（详见<http://www.cs.toronto.edu/~>

这可能影响我们训练程序的性能，因为它无法区分不同长期期望行为策略之间的差异。我们采用大小为1000的滑动平均窗口，将参数在最初一百万帧内线性退火从1.0降至0.1，此后固定为0.1。我们总共训练了五千万帧（相当于约38天的游戏体验），并使用包含最近一百万帧的回放记忆。

沿袭先前运行Atari 2600游戏的方法，我们同样采用简单的帧跳过技术¹⁵。更精确地说，智能体每隔k帧（而非每帧）观察并选择动作，且在跳过的帧中重复其最后一次动作。由于向前运行模拟器一步所需的计算量远低于智能体选择动作所需，该技术使智能体能在不显著增加运行时间的前提下，完成约k倍的游戏量。所有游戏均采用k=5.4的设置。

所有超参数和优化参数的取值均通过在《Pong》《Breakout》《Seaquest》《Space Invaders》和《Beam Rider》等游戏中进行非正式搜索确定。因计算成本过高，我们未进行系统化的网格搜索。这些参数随后在所有其他游戏中保持固定。所有超参数的具体数值及说明详见扩展数据表1。

我们的实验设置仅基于以下最基本的先验知识：输入数据包含视觉图像（这促使我们采用卷积深度神经网络），游戏特有的得分（未作修改），以及动作数量（但不包括动作对应关系，例如向上按钮的具体定义），此外还包含生命值计数。

评估流程。训练后的智能体通过以下方式进行评估：在不同初始随机条件下（“无操作”；详见扩展数据表1）进行30次游戏，每次游戏时长不超过5分钟，并采用e=0.05的e-贪婪策略。此流程旨在最大限度降低评估过程中的过拟合风险。随机智能体作为基准对照组，以10Hz频率（即每六帧一次）随机选择动作，并在间隔帧重复上次动作。10Hz接近人类玩家按下“射击”按钮的极限速度，此设定可避免少数游戏中出现异常基准分数。我们还评估了60Hz（即每帧）随机动作选择策略的性能。其影响微乎其微：仅在六款游戏（拳击、打砖块、疯狂攀登者、恶魔攻击、克鲁尔和机器人坦克）中使归一化DQN性能波动超过5%，且所有这些游戏中DQN的表现均显著优于人类专家。

专业人类测试员使用与智能体相同的模拟器引擎，并在受控条件下进行游戏。人类测试者不得暂停、保存或重新加载游戏。与原始雅达利2600环境一致，模拟器以60Hz频率运行且禁用音频输出：由此确保人类玩家与智能体获得等效的感官输入。人类表现数据为每款游戏约20轮对局（每轮最长5分钟）的平均奖励值，此前每款游戏均经过约2小时练习。

算法。我们考虑代理通过一系列动作、观察和奖励与环境（本例中为Atari模拟器）交互的任务。在每个时间步，代理从合法游戏动作集 $A \sim \{1, \dots, K\}$ 中选择动作 a_t 。该动作传递至模拟器，从而改变其内部状态和游戏得分。通常环境具有随机性。智能体无法直接观察模拟器的内部状态，而是接收模拟器输出的图像 $x_{(t)} \in \mathbb{R}^{(d)}$ ——该图像作为像素值向量呈现当前屏幕状态。同时智能体还会获得代表游戏分数变化的奖励 r_t 。需注意：游戏得分通常取决于整个历史动作序列与观测序列；某次动作的反馈可能需经过数千个时间步长后才显现。

由于智能体仅能观察当前屏幕，该任务属于部分可观察任务³³，且许多仿真状态存在感知混淆（即仅凭当前屏幕无法完全理解当前状况）。因此，动作与观察序列 $s_{(t)} = x_{(t)}, a_{(1)}, x_{(2)}, \dots, a_{(t-1)}, x_{(t)}$ 被输入算法，该算法据此序列学习游戏策略。模拟器中所有序列均假定在有限时间步数内终止。这种形式化处理构成了庞大但有限的马尔可夫决策过程（MDP），其中每个序列对应独立状态。由此，我们可直接采用标准强化学习方法处理MDP，并将完整序列 $s_{(t)}$ 作为时间t的状态表示即可。

该智能体的目标是通过选择能最大化未来奖励的动作与模拟器交互。我们采用标准假设：未来奖励按时间步长以系数c进行折现（c值全程设为0.99），

将时间t的未来折现回报定义为 $R_t \sim \sum_{t'=t}^{\infty} c^{t'-t} r_{t'}$ ，其中T是

游戏终止的时间步长。我们将最优动作价值函数 $Q^*(s,a)$ 定义为：在观察序列s后采取动作a时，通过任何策略可获得的最大预期回报。 $Q^*(s,a) \sim \max_p \mathbb{E}[R_t | s_t = s, a_t = a, p]$ 其中p是将序列映射到动作的策略（或

动作分布）。

最优动作价值函数遵循一个重要的恒等式，即贝尔曼方程。其原理基于以下直观认识：若已知序列s在下一个时间步对所有可能动作a的最优值 $Q^*(s,a)$ ，则最优策略是选择使 $r + cQ^*(s',a')$ 期望值最大化的动作a'：

$$Q^*(s,a) \sim \mathbb{E}_a [r + c \max_{a'} Q^*(s',a') | D_{s,a}]$$

许多强化学习算法的基本思想是通过贝曼方程进行迭代更新来估计动作价值函数： $Q_{t+1}(s,a) \leftarrow \mathbb{E}_a [r + c \max_{a'} Q_t(s',a') | D_{s,a}]$ 。此类价值迭代算法在无穷时数收敛至最优动作价值函数 $Q_{(t)} = Q^*(s,a)$ 。实际应用中该基础方法难以实施，因其对每个序列单独估计动作价值函数且缺乏泛化能力。因此通常采用函数近似器来估计动作价值函数： $Q(s,a; \mathbf{h}) \approx Q^*(s,a)$ 。在强化学习领域，这通常采用线性函数近似器，但

有时会改用非线性函数逼近器，例如神经网络。我们称具有权重 $\mathbf{h}$ 的神经网络函数逼近器为 Q 网络。 Q 网络可在迭代 i 时调整参数 $\mathbf{h}_i$ ，以降低贝尔曼方程中的均方误差来训练，其中最优解为

目标值 $r + \gamma \max_a Q(s, a)$ 被近似目标值替换
 $y = r + \gamma \max_a Q(s, a; \mathbf{h}^i)$ ，使用来自先前迭代的参数 $\mathbf{h}_i$ 。
 这导致损失函数序列 $L_i(\mathbf{h}_i)$ 在每次迭代 i 中发生变化，

$$L_i(\mathbf{h}_i) = \mathbb{E}_{s,a,r} (E_s[yD(s,a) - Q(s,a; \mathbf{h}_i)]^2) \\ \sim \mathbb{E}_{s,r,r'} (y \{Q(s,a; \mathbf{h}_i) - zE_{s,a,r}[V_{\pi}]\})^2$$

请注意，目标函数依赖于网络权重；这与监督学习中使用的目标函数不同，后者在学习开始前即为固定值。在每次优化阶段，我们保持前一迭代 $\mathbf{h}^i$ 的参数固定，同时优化第 i 个损失函数 $L_i(\mathbf{h}_i)$ ，从而形成一组定义明确的优化问题序列。最后一项是目标值的方差，它不依赖于当前优化的参数 $\mathbf{h}_i$ ，因此可忽略。对损失函数求导可得如下梯度：

$$\nabla_{\mathbf{h}_i} L(\mathbf{h}_i) \sim \mathbb{E}_{s,a,r} \left[\left(r + \gamma \max_a Q(s,a; \mathbf{h}^i) - Q(s,a; \mathbf{h}_i) \right) \nabla_{\mathbf{h}_i} Q(s,a; \mathbf{h}_i) \right]$$

相较于计算上述梯度中的完整期望值，通常采用通过随机梯度下降优化损失函数在计算上更为便捷。在该框架下，可通过每次时间步更新权重、用单样本替代期望值，并设定 $\mathbf{h}^i \sim \mathbf{h}_{i-1}$ 来再现经典的 Q 学习算法³⁰。

请注意，该算法属于无模型学习：它直接利用仿真器的样本解决强化学习任务，无需显式估计奖励与状态转移概率分布 $P(r, s' | D(s, a))$ 。同时它也属于离策略学习：在遵循确保充分探索状态空间的行为分布时，该算法通过贪婪策略 $a = \arg\max_a Q(s, a; \mathbf{h})$ 进行学习。实践中，行为分布通常由 ϵ -贪婪策略选择：该策略以概率 $1 - \epsilon$ 遵循贪婪策略，其余概率 ϵ 下随机选择动作。深度 Q 网络训练算法。深度 Q 网络的完整训练算法如算法 1 所示。智能体根据基于 Q 函数的 ϵ -贪婪策略选择并执行动作。由于将任意长度的历史数据作为神经网络输入较为困难，我们的 Q 函数改为处理由上述 w 函数生成的固定长度历史表示。该算法通过两种方式修改标准在线 Q 学习，使其适用于训练大型神经网络而不致发散：

首先，我们采用经验回放技术³¹，其中存储代理在每个时间步的状态体验 $e_t = (s_t, a_t, r_t, s_{t+1})$ ，构成数据集 $D = \{e_1, \dots, e_t\}$ ；

在多个子代中累积（其中子代结束于某个终止子代出现时）状态达到终止条件的）的经验样本池中。在算法的内部循环中，我们对从存储样本池中随机抽取的经验样本 (s, a, r, s') 进行 Q 学习更新（即小批量更新）。这种方法

相较于标准在线 Q 学习具有多重优势。首先，每次经验步骤可用于多次权重更新，从而提升数据效率。其次，连续样本间存在强相关性，直接学习会导致低效；随机化样本可打破相关性，从而降低更新方差。第三，当在线学习时——

政策当前参数决定了参数训练所依据的下一个数据样本。例如，若最大化动作是向左移动，则训练样本将以左侧样本为主；若最大化动作随后转向右侧，训练分布也将随之切换。由此不难看出，系统可能产生不良反馈循环，导致参数陷入次优局部极小值，甚至发生灾难性遗忘⁽³²⁾。通过采用经验

行为回放的分布是通过其多个先前状态的平均值计算得出，这能平滑学习过程并避免参数出现振荡或发散。需注意的是，在基于经验回放的学习中，必须采用离策略学习（因为当前参数与生成相同样本时使用的参数不同）

ple），这促使我们选择 Q 学习法。

实际中，我们的算法仅在回溯表中存储最近 N 个经验元组。在执行更新时，该方法采用记忆缓冲区机制，并从 D 中均匀随机抽样。这种方法在某些方面存在局限性：由于内存容量 N 有限，记忆缓冲区无法区分重要过渡状态，总是用最新过渡状态覆盖旧数据。同样地，均匀采样机制使重放记忆中所有过渡状态获得同等权重。更复杂的采样策略或许应侧重于能带来最大学习价值的过渡状态，类似于优先级扫描⁽³³⁾的方法。

在线 Q 学习的第二项改进旨在进一步提升神经网络方法的稳定性，具体做法是为 Q 学习更新中的目标值 y 生成过程采用独立网络。更精确地说，每进行 C 次更新，我们便克隆网络 Q 以获得目标 $Q^\wedge$ ，并使用 $Q^\wedge$ 生成

Q 学习目标 y 用于后续 C 次 Q 更新。相较于标准在线 Q 学习（每次更新直接使用原始网络），此修改显著增强了算法稳定性。增加 $Q(s,a)$ 通常也会增加所有 a 的 $Q(s, \cdot, a)$ ，从而也增加了

目标 y ，这可能导致策略的振荡或发散。生成使用旧参数集处理目标会导致更新 Q 与更新影响目标 y 之间产生延迟，从而引发收敛问题或使得振荡现象变得极不可能发生。

我们还发现，将误差项从更新公式中截取有助于理解： $r + \gamma \max_a Q(s, a; \mathbf{h}^i) - Q(s,a; \mathbf{h})$ 误差项需限制在 -1 至 1 之间。由于绝对值损失函数 $|x|$ 对所有负值 x 的导数为 -1 ，对所有正值 x 的导数为 1 ，将平方误差限制在 -1 至 1 区间相当于对 $(-1, 1)$ 区间外的误差采用绝对值损失函数。这种误差裁剪形式进一步提升了算法的稳定性。算法 1：基于经验重放的深度 Q 学习。

初始化回放记忆库 D 至容量 N

初始化动作-价值函数 Q 并赋予随机权重 $\mathbf{h}$ 初始化目标动作-价值函数 $Q^\wedge$ 并

赋予权重 $\mathbf{h}^2 = \mathbf{h}$ 对于第 $1, M$ 个片段执行

初始化序列 $s_1 \sim \{x_1\}$ 及预处理序列 $w_1 \sim w(s_1)$

对于 $t = 1, T$ 执行

以概率 ϵ 随机选择动作 a_t

否则选择 $a_t = \arg\max_a Q(w(s_t), a; \mathbf{h})$

在仿真器中执行动作 a_t ，观察奖励 r_t 和图像 x_{t+1}

设置 $s_{t+1} = s_t, a_t, x_{t+1}$ 并预处理 $w_{t+1} = w(s_{t+1})$

存储状态转移 w_t, a_t, r_t, w_{t+1} 于 D

随机小批次转换 w_j, a_j, r_j, w_{j+1} 若在步骤 $j+1$ 终止 来自 D

$\tilde{r}_j = r_j + \gamma \max_a Q^\wedge(w_{j+1}, a; \mathbf{h}^i)$ 否则

对 $y = Q(w, a; \cdot)$ 执行梯度下降步，针对 j


网络参数 $\mathbf{h}$

每隔 C 步重置 $Q^\wedge \sim Q$

结束循环



结束循环

31. Jarrett, K., Kavukcuoglu, K., Ranzato, M. A. & LeCun, Y. 物体识别最优多阶段架构是什么？*IEEE 国际计算机视觉会议论文集*, 2146–2153 页（2009）。
32. 奈尔, V. & 辛顿, G. E. 整流线性单元改进限制玻尔兹曼机。 *国际机器学习会议论文集* 807–814 (2010).
33. 凯尔布林, L. P., 利特曼, M. L. & 卡桑德拉, A. R. 《部分可观测随机环境中的规划与执行》。《*人工智能*》101 卷, 99–134 页 (1994)。



扩展数据图1 | DQN对人类与智能体在《太空侵略者》中联合游戏过程中所经历的游戏状态，在最后隐藏层赋予的表示进行二维t-SNE嵌入。该图通过对人类（30分钟）与智能体（2小时）联合游戏过程中，DQN对游戏状态在最后隐藏层赋予的表示运行t-SNE算法²⁸生成。人类游戏状态（橙色点）与智能体游戏状态（蓝色点）对应的二维嵌入结构呈现相似性，表明DQN所学习的表示确实能泛化至自身策略之外生成的数据。

点）与DQN游戏状态（蓝色点）的对应关系显示，DQN学习到的表示确实能推广至其自身策略之外生成的数据。t-SNE嵌入图中出现重叠的点簇，对应于人类与智能体游戏过程中状态的网络表示，表明DQN智能体遵循的状态序列与人类游戏中发现的序列相似。选定状态对应的屏幕截图如下图所示（人类：橙色边框；DQN：蓝色边框）。



扩展数据图2 | 两种游戏（打砖块与乒乓球）中学习到的价值函数可视化。a，打砖块游戏中学习到的价值函数可视化。在时间点1和2，状态值预测为0.17，智能体正在清除最低层的砖块。价值函数曲线中的每个峰值对应清除一块砖块获得的奖励。在时间点3，智能体即将突破顶层砖块，预期突破后将清除大量砖块，价值随之升至0.21。时间点4时价值超过0.23，智能体成功突破。此后，球体将在砖块上部区域弹跳，自动清除大量砖块。b. 乒乓球游戏中学习到的动作价值函数可视化。时间点1时，球体正朝屏幕右侧由智能体控制的拍板移动，此时

所有动作的期望值均在0.7左右，反映了基于先前经验的该状态预期值。在时间点2，智能体开始将球拍移向来球，此时“上”动作的期望值保持高位，而“下”动作的期望值则降至0.9。这表明按下“下”键将导致智能体失球并承担21的惩罚值。在时间点3，智能体通过按下“上”键击中球体，预期奖励持续上升直至时间点4——此时球体抵达屏幕左边缘，所有动作的数值均表明智能体即将获得1的奖励。需注意，虚线仅为示意球体过往轨迹（即游戏过程中不会显示）。经Atari Interactive, Inc.授权使用。

扩展数据表1 | 超参数及其取值列表

Hyperparameter	Value	Description
minibatch size	32	Number of training cases over which each stochastic gradient descent (SGD) update is computed.
replay memory size	1000000	SGD updates are sampled from this number of most recent frames.
agent history length	4	The number of most recent frames experienced by the agent that are given as input to the Q network.
target network update frequency	10000	The frequency (measured in the number of parameter updates) with which the target network is updated (this corresponds to the parameter C from Algorithm 1).
discount factor	0.99	Discount factor gamma used in the Q-learning update.
action repeat	4	Repeat each action selected by the agent this many times. Using a value of 4 results in the agent seeing only every 4th input frame.
update frequency	4	The number of actions selected by the agent between successive SGD updates. Using a value of 4 results in the agent selecting 4 actions between each pair of successive updates.
learning rate	0.00025	The learning rate used by RMSProp.
gradient momentum	0.95	Gradient momentum used by RMSProp.
squared gradient momentum	0.95	Squared gradient (denominator) momentum used by RMSProp.
min squared gradient	0.01	Constant added to the squared gradient in the denominator of the RMSProp update.
initial exploration	1	Initial value of ϵ in ϵ -greedy exploration.
final exploration	0.1	Final value of ϵ in ϵ -greedy exploration.
final exploration frame	1000000	The number of frames over which the initial value of ϵ is linearly annealed to its final value.
replay start size	50000	A uniform random policy is run for this number of frames before learning starts and the resulting experience is used to populate the replay memory.
no-op max	30	Maximum number of "do nothing" actions to be performed by the agent at the start of an episode.

所有超参数的取值均通过在《Pong》《Breakout》《Seaquest》《Space Invaders》和《Beam Rider》等游戏中进行非正式搜索确定。由于计算成本过高，我们未进行系统化的网格搜索，但可以设想，通过系统性调整超参数值或可获得更优结果。

扩展数据表2 | DQN代理获得的游戏得分与文献方法^{12,15}及专业人类游戏测试员的比较

Game	Random Play	Best Linear Learner	Contingency (SARSA)	Human	DQN ($\pm$ std)	Normalized DQN (% Human)
Alien	227.8	939.2	103.2	6875	3069 ($\pm$ 1093)	42.7%
Amidar	5.8	103.4	183.6	1676	739.5 ($\pm$ 3024)	43.9%
Assault	222.4	628	537	1496	3359($\pm$ 775)	246.2%
Asterix	210	987.3	1332	8503	6012 ($\pm$ 1744)	70.0%
Asteroids	719.1	907.3	89	13157	1629 ($\pm$ 542)	7.3%
Atlantis	12850	62687	852.9	29028	85641($\pm$ 17600)	449.9%
Bank Heist	14.2	190.8	67.4	734.4	429.7 ($\pm$ 650)	57.7%
Battle Zone	2360	15820	16.2	37800	26300 ($\pm$ 7725)	67.6%
Beam Rider	363.9	929.4	1743	5775	6846 ($\pm$ 1619)	119.8%
Bowling	23.1	43.9	36.4	154.8	42.4 ($\pm$ 88)	14.7%
Boxing	0.1	44	9.8	4.3	71.8 ($\pm$ 8.4)	1707.9%
Breakout	1.7	5.2	6.1	31.8	401.2 ($\pm$ 26.9)	1327.2%
Centipede	2091	8803	4647	11963	8309($\pm$ 5237)	63.0%
Chopper Command	811	1582	16.9	9882	6687 ($\pm$ 2916)	64.8%
Crazy Climber	10781	23411	149.8	35411	114103 ($\pm$ 22797)	419.5%
Demon Attack	152.1	520.5	0	3401	9711 ($\pm$ 2406)	294.2%
Double Dunk	-18.6	-13.1	-16	-15.5	-18.1 ($\pm$ 2.6)	17.1%
Enduro	0	129.1	159.4	309.6	301.8 ($\pm$ 24.6)	97.5%
Fishing Derby	-91.7	-89.5	-85.1	5.5	-0.8 ($\pm$ 19.0)	93.5%
Freeway	0	19.1	19.7	29.6	30.3 ($\pm$ 0.7)	102.4%
Frostbite	65.2	216.9	180.9	4335	328.3 ($\pm$ 250.5)	6.2%
Gopher	257.6	1288	2368	2321	8520 ($\pm$ 3279)	400.4%
Gravitar	173	387.7	429	2672	306.7 ($\pm$ 223.9)	5.3%
H.E.R.O.	1027	6459	7295	25763	19950 ($\pm$ 158)	76.5%
Ice Hockey	-11.2	-9.5	-3.2	0.9	-1.6 ($\pm$ 2.5)	79.3%
James Bond	29	202.8	354.1	406.7	576.7 ($\pm$ 175.5)	145.0%
Kangaroo	52	1622	8.8	3035	6740 ($\pm$ 2959)	224.2%
Krull	1598	3372	3341	2395	3805 ($\pm$ 1033)	277.0%
Kung-Fu Master	258.5	19544	29151	22736	23270 ($\pm$ 5955)	102.4%
Montezuma's Revenge	0	10.7	259	4367	0 ($\pm$ 0)	0.0%
Ms. Pacman	307.3	1692	1227	15693	2311($\pm$ 525)	13.0%
Name This Game	2292	2500	2247	4076	7257 ($\pm$ 547)	278.3%
Pong	-20.7	-19	-17.4	9.3	18.9 ($\pm$ 1.3)	132.0%
Private Eye	24.9	684.3	86	69571	1788 ($\pm$ 5473)	2.5%
Q*Bert	163.9	613.5	960.3	13455	10596 ($\pm$ 3294)	78.5%
River Raid	1339	1904	2650	13513	8316 ($\pm$ 1049)	57.3%
Road Runner	11.5	67.7	89.1	7845	18257 ($\pm$ 4268)	232.9%
Robotank	2.2	28.7	12.4	11.9	51.6 ($\pm$ 4.7)	509.0%
Seaquest	68.4	664.8	675.5	20182	5286($\pm$ 1310)	25.9%
Space Invaders	148	250.1	267.9	1652	1976 ($\pm$ 893)	121.5%
Star Gunner	664	1070	9.4	10250	57997 ($\pm$ 3152)	598.1%
Tennis	-23.8	-0.1	0	-8.9	-2.5 ($\pm$ 1.9)	143.2%
Time Pilot	3568	3741	24.9	5925	5947 ($\pm$ 1600)	100.9%
Tutankham	11.4	114.3	98.2	167.6	186.7 ($\pm$ 41.9)	112.2%
Up and Down	533.4	3533	2449	9082	8456 ($\pm$ 3162)	92.7%
Venture	0	66	0.6	1188	3800 ($\pm$ 238.6)	32.0%
Video Pinball	16257	16871	19761	17298	42684 ($\pm$ 16287)	2539.4%
Wizard of Wor	563.5	1981	36.9	4757	3393 ($\pm$ 2019)	67.5%
Zaxxon	32.5	3365	21.4	9173	4977 ($\pm$ 1235)	54.1%

最佳线性学习器是线性函数逼近器在不同类型人工设计特征上获得的最佳结果¹⁵。SARSA（随机增强自回归强化学习）智能体数据源自参考文献15。请注意最后一列数据表示DQN相对于人类游戏测试员的性能表现，以百分比形式呈现，即100.3（DQN得分 - 随机游戏得分）/（人类得分 - 随机游戏得分）。

扩展数据表3 | 重播与目标Q网络分离的影响

Game	With replay, with target Q	With replay, without target Q	Without replay, with target Q	Without replay, without target Q
Breakout	316.8	240.7	10.2	3.2
Enduro	1006.3	831.4	141.9	29.1
River Raid	7446.6	4102.8	2867.7	1453.0
Seaquest	2894.4	822.6	1003.0	275.8
Space Invaders	1088.9	826.3	373.2	302.0

DQN智能体采用标准超参数进行1000万帧训练，涵盖所有可能的组合：开启或关闭转向回放、是否使用独立目标Q网络，以及三种不同的学习率。每个智能体每训练25万帧进行评估，共进行13.5万帧验证，最终报告最高平均回合得分。需注意：本次评估回合未在5分钟处截断，因此Enduro平台得分高于扩展数据表2所示结果。另需说明：训练帧数（1000万帧）较扩展数据表2主结果（5000万帧）有所缩减。

扩展数据表4 | DQN与线性函数逼近器的性能对比

游戏	DQN	线性
Breakout	316.8	3.00
耐力	1006.3	62.0
河流突袭	7446.6	2346.9
海底探险队	2894.4	656.9
太空侵略者	1088.9	301.3

DQN代理在5个验证游戏中的表现与线性函数逼近器进行了对比（即使用单层线性层替代卷积网络，并结合回放和独立目标网络）。采用标准超参数及三种不同学习率训练代理1000万帧。每26万训练帧对每个代理进行评估，共验证13.6万帧，最终报告最高平均回合得分。需注意：本次评估回合未在5分钟时截断，导致Enduro平台得分高于扩展数据表2所示结果。另需说明：训练帧数（1000万帧）较扩展数据表2主结果（5000万帧）有所缩减。